



张海超

电话: 18279159611 | 地址: 苏州

邮箱: zhang_haichao@163.com

[Google Scholar](#) | [GitHub](#) | [Personal Website](#)

教育背景

利物浦大学, PhD (人工智能与大语言模型) 2024.06 – 至今

- 研究方向聚焦大语言模型 (LLM)、基础模型、检索增强生成 (RAG)、生成式推理与模型优化。

西交利物浦大学, 计算机科学硕士 2022.09 – 2024.03

- 硕士成绩获 **Distinction (优秀)**, 专业排名 **Top 1%**。

华东交通大学, 计算机科学与技术学士 2014.09 – 2018.06

- 平均分 **87/100**, 专业排名 **Top 1%**。

工作经历

北京阿里巴巴软件技术有限公司, 开发工程师 2018.11 – 2022.08

- 负责阿里广告投放与推荐相关数据平台研发, 覆盖人群引擎、巡检归因与标签计算等核心系统。
- 参与大规模数据平台、复杂业务系统与核心引擎平台建设, 具备高并发、复杂场景下的系统研发与优化经验。

鼎复数据科技 (北京) 有限公司, 开发工程师 2018.07 – 2018.11

- 参与计算机视觉算法研发, 负责图像处理相关项目, 主要研究图片转表格、去除水印等工作。

学术研究

基于大语言模型与检索增强生成的定制化 RAG 研究 2025.01 – 2025.05

- 第一作者论文 Customized Retrieval-Augmented Generation with LLM for Debiasing Recommendation Unlearning, 已被 ICDM 2025 (CCF-B) 接收。
- 提出 CRAGRU 框架, 将大语言模型与检索增强生成 (RAG) 结合, 实现细粒度知识检索、上下文构建与生成推理, 并在多个基准数据集上验证了方法有效性。项目主页: <https://zhang-haichao.github.io/CRAGRU-Page>
- 研究涉及 LLM、RAG、检索增强、上下文建模、生成式推理等技术。

基于 Prompt Tuning 与知识蒸馏的参数高效模型适配研究 2025.04 – 2025.08

- 第一作者论文 Teaching to Forget: Dual-Teacher Distilled Prompt-Tuning for Efficient Recommendation Unlearning, 已投稿 SIGIR 2026 (CCF-A)。
- 结合双教师蒸馏与参数高效 Prompt Tuning, 在不重训主模型的条件下实现特定行为的轻量化调节。
- 研究涉及 PEFT、Prompt Learning、知识蒸馏、参数高效适配等技术。

基于推理时控制的可控生成研究 2025.10 – 2026.01

- 第一作者论文 Controllable Generative Recommendation via Guided Token Refinement, 已投稿 IJCAI 2026。
- 提出可控生成框架 ReGen, 将生成过程重构为基于 Semantic ID 的并行迭代细化过程, 实现推理阶段的实时控制。
- 研究涉及 Transformer、生成式建模、推理时控制、并行解码、约束生成等技术, 并在准确性与多样性之间取得平衡。

- 第一作者论文 Personalized Conformity Disentanglement for Debiased Recommendations。
- 提出 PCDR 框架，基于用户动态行为序列分离兴趣表征与从众表征，提升个体级建模能力。
- 研究涉及 Transformer、序列建模、Attention、因果推断、对比学习等技术，并在多个数据集上验证了方法有效性。

论文与成果

- Explain-then-Forget: Causal Explanation-based Unlearning for Efficient and Precise Recommendation, ICDM 2026。
- Controllable Generative Recommendation via Guided Token Refinement, ICDM 2026。
- Explaining Graph Recommendations via Counterfactual Support Sets, ICONIP 2026。
- Topology-Aware Inverse Preference Learning for Robust Hybrid Voting Systems, ICONIP 2026。
- Customized Retrieval-Augmented Generation with LLM for Debiasing Recommendation Unlearning, ICDM 2025。
- Machine Vision-Enabled Octahedral Network Reconstruction and Structural Analysis of Perovskite Quantum Dots, ACS NANO。
- Clustering-based Incremental Learning for Imbalanced Data Classification, Knowledge-Based Systems。
- Uncertainty-Aware Semantic Decoding for LLM-Based Sequential Recommendation, APWEB 2025。
- Counterfactual Contrastive Learning for Fine Grained Image Classification, ICANN 2024。
- Two-branch Network with Feature Fusion for Time Since Deposition Estimation of Bloodstains, CSCWD 2024。

知识产权

- 发明专利: 一种基于个性化因果分解的去偏方法及推荐系统；
公开号: CN117312675A；公开日: 2023 年 12 月 29 日。
- 软件著作权: 基于个性化从众解耦的无偏推荐算法系统 V1.0；
登记号: 2025SR0516629；登记日期: 2025 年 3 月 25 日。
- 软件著作权: 移动互联网 + 拼车模式下大规模路网出租车动态调度组织平台；[易步 V1.0]
登记号: 2018SR047738；登记日期: 2018 年 1 月 22 日。
- 软件著作权: 基于安卓的铁路设备巡检系统；[铁路巡检设备 APP V1.0]
登记号: 2018SR717297；登记日期: 2018 年 9 月 6 日。
- 软件著作权: 基于 WEB 端的铁路设备巡检系统；[铁路巡检设备系统 V1.0]
登记号: 2018SR643652；登记日期: 2018 年 8 月 13 日。

项目经历

人群引擎管控平台	2020.04 – 2022.09
• 面向阿里广告投放数据平台，负责核心人群引擎的统一管控、流程可视化与异常定位能力建设。 • 担任项目负责人，完成平台设计、核心功能开发与系统落地，协同引擎负责人推进接口设计与平台迭代。 • 项目落地后成为核心管控平台，显著提升问题排查与运营效率。	
百万人群巡检归因平台	2020.04 – 2022.09
• 面向阿里广告投放核心链路，负责百万人群巡检、异常发现、归因分析与问题修复闭环建设。 • 担任项目负责人，完成系统架构设计与核心框架开发，协同多个模块负责人推进全链路落地。 • 系统上线后支撑数十条业务线，客户投诉率下降超过 90%。	
实时标签计算与人群构建引擎	2019.07 – 2020.03

- 面向广告投放场景，负责实时标签计算与人群构建引擎设计及核心模块开发。
- 基于图计算完成标签生产链路优化，覆盖计算内核、索引设计与 DSL 定义等关键模块。
- 标签迭代时间由 7 天缩短至 0.5 天，计算资源节省约 70%。

个人技能

- **编程语言：**Python（4 年经验）、Java（6 年经验）。
- **深度学习框架：**熟练使用 PyTorch，能够独立完成模型设计、训练、评测与优化。
- **大模型技术：**熟悉 LLM、RAG、Transformer、Prompt Tuning、知识蒸馏、模型推理、参数编辑。
- **系统与数据能力：**具备 Flink、MapReduce、HBase、Spring Cloud、MySQL 等大数据与应用系统开发经验。
- **科研能力：**具备从问题抽象、算法设计、实验验证到论文写作的完整科研流程经验。
- **语言与证书：**LanguageCert IESOL C1 Pass；中级职称 / 软件设计师。

荣誉奖项

- 华东交通大学 ACM 程序设计竞赛一等奖（2015.11）。
- 江西省计算机作品赛暨“互联网+”创新创业大赛省级二等奖（2016.06）。
- 全国交通类大学生优秀论文一等奖（2016.09）。
- 中国大学交通学院创客大赛暨“互联网交通”创新创业大赛全国三等奖（2016.11）。

个人总结

- 兼具工业级系统研发与学术研究经历，既有阿里大规模数据平台与高并发系统建设经验，也有大模型方向持续科研产出。
- 研究方向聚焦 LLM、RAG、可控生成、知识编辑与参数高效适配，具备从问题定义、算法设计到实验验证的完整研究能力。
- 编程基础扎实，具备独立推进复杂项目与跨团队协作落地能力，能够在高要求场景下稳定交付结果。